Criteo 广告归因与预算效率分析

业务分析报告

- 数据：Criteo Attribution Modeling 公开数据集
- 分析日期：2026-11-01
- 分析工具：DuckDB、SQL、Python、pandas、SciPy、Matplotlib
- 复现入口：项目根目录下的 3 个 Notebook

摘要

本项目回答两个与广告预算直接相关的问题：

1. 转化信用是否被不合理地集中到某一类广告触点？
2. 活动之间的效率差异是否足以支持预算调整实验？

分析使用 16,468,027 行曝光日志、6,142,256 个用户、675 个活动和 438,730 个转化事件。主要结论如下：

结论	关键证据	业务含义
中间点击存在明显成本与信用错配	占完整路径成本 37.50%，三种非末次归因模型的平均信用仅 5.01%	不应直接按当前成本继续给中间点击分配预算，应先做降价实验
活动效率差异显著	高效组 155 个活动 CPA 0.0063，低效组 333 个活动 CPA 0.0466，相差 7.4 倍	预算优先级存在明显优化空间，但 7.4 倍不是可直接兑现的收益
绝对 CPA 不适合对外比较	不同 CTR 假设下，加权 CPA 从 4.3085 变化到 0.0204，相差约 211 倍	只使用样本内相对排序，不引用绝对金额作为行业基准
活动相对排序较稳定	所有敏感性情景下 CTR 排名相关为 1.0000，CPA 排名相关不低于 0.9687	预算排序比绝对成本水平更可靠
高频曝光进入低边际效率区间	每千曝光转化事件在 16 至 30 次曝光后基本走平，单次转化成本继续上升	应控制第 30 次以上曝光，优先覆盖低频用户
7 天窗口适合观察，但不是最低边际成本	覆盖 79.1% 完整路径事件和 75.2% 完整路径成本；边际 CPA 为 0.00242，高于 30 天窗口的 0.00190	成本观察使用 7 天，完整效果评估使用 30 天

建议先做小范围实验，不直接把分析得到的相对系数当成最终出价倍数。

---

1. 业务问题与决策范围

广告预算分配同时发生在两个层级：

- **活动层**：哪些活动值得增加预算，哪些活动需要降本或关停？
- **触点层**：一次转化应如何在首次、中间和末次点击之间分配信用？

本项目支持的是预算排序和实验优先级，不等同于因果增益测算。数据中缺少随机实验、反事实标签和收入信息，因此：

- CPA 只作为归因事件的成本效率指标，不代表利润或 ROI。
- 归因模型只回答现有转化信用如何分配，不回答某个触点带来了多少增量。
- 任何预算调整都需要小流量 A/B 测试或随机 holdout 验证。

---

2. 数据与口径

2.1 数据概况

指标	数值
原始曝光日志	16,468,027 行
用户数	6,142,256
活动数	675
时间范围	day 0 至 day 30，共 31 个自然日，末日存在截断
点击行数	5,947,563
样本点击率	36.12%
转化行数	806,196
转化事件数	438,730
官方归因事件数	237,157
全站成本	4,829.34，成本单位为匿名化口径，不代表真实货币金额
完整路径成本	580.27，占全站成本约 12.0%

2.2 数据粒度

一行原始数据代表一次广告曝光。同一行可以同时带有点击、转化和官方归因标记。

为了避免粒度混用，分析建立了两层核心表：

- **转化事件层**：按 `(uid, conversion_id)` 唯一确定一次转化，共 438,730 行。
- **路径触点层**：一行代表一次转化路径中的一次点击，共 806,196 行。

位置归因只使用首次和末次点击均可验证、且路径行数等于 `click_nb` 的完整路径：

- 完整路径事件：362,504 个，占全部转化事件 82.63%。
- 完整路径触点：600,145 行。
- 缺少真实首次点击的事件：38,578 个，占 8.79%。
- 缺少真实末次点击的事件：37,648 个，占 8.58%。

2.3 关键字段

字段或概念	口径
`click`	当前曝光是否被点击

字段或概念	口径
`conversion`	当前行是否带转化标记
`attribution`	事件级布尔值，表示官方是否接受该转化归因，不是行级信用
`click_pos`	路径中的 0-based 点击位置
`click_nb`	路径点击总数
真实末次点击	`click_pos = click_nb - 1`
`-1`	当前字段对该行不适用，不是普通缺失值
`conversion_id`	用户内唯一的转化事件 ID

数据口径中最重要的一点是：不能用当前观测路径的最早或最晚一行冒充真实首次、末次点击。路径不完整的事件不参与位置归因。

---

3. 分析方法

3.1 处理流程

```
原始 TSV
  -> DuckDB 读取与字段类型固定
  -> 漏斗、活动与日期汇总
  -> 转化事件表和路径触点表
  -> 四种归因信用
  -> IPW 敏感性、频次和窗口分析
  -> 最终业务结论与 Tableau 数据导出
```

DuckDB 负责大表读取和主要聚合，pandas 和 SciPy 用于结果整理、Spearman 排名相关和绘图。

3.2 活动效率

活动效率使用归因事件 CPA：

```
归因事件 CPA = 活动成本 / 官方归因事件数
```

活动动作分析只纳入归因事件不少于 30 的活动，以避免极小分母造成过度波动；再用 100 个归因事件区分主力活动和测试活动。最终得到 488 个活动，覆盖全部活动成本的 94.1%。

以加权 CPA 基准划分四类动作：

- A：低 CPA，归因事件不少于 100，优先加预算。
- B：低 CPA，归因事件 30 至 99，观察或扩量测试。
- C：高 CPA，归因事件不少于 100，优先优化降本。
- D：高 CPA，归因事件 30 至 99，重定向测试或考虑关停。

3.3 归因模型

项目使用四种可解释的规则型归因模型：

1. **Last-click**：真实末次点击获得全部信用。
2. **Linear**：路径内所有点击平均分配信用。
3. **Position 40/20/40**：首次和末次各获得 40%，中间点击合计获得 20%。
4. **Time-decay**：使用 7 天半衰期，距离转化越近的点击权重越高。

每个转化事件的信用总和恒为 1。相对出价系数定义为：

```
相对出价系数 = 三模型平均信用占比 / 成本占比
```

三模型为 linear、position 40/20/40 和 time-decay；last-click 作为基线对照，不进入平均值。该系数只适用于完整路径内部，不代表真实出价倍数。

3.4 稳健性分析

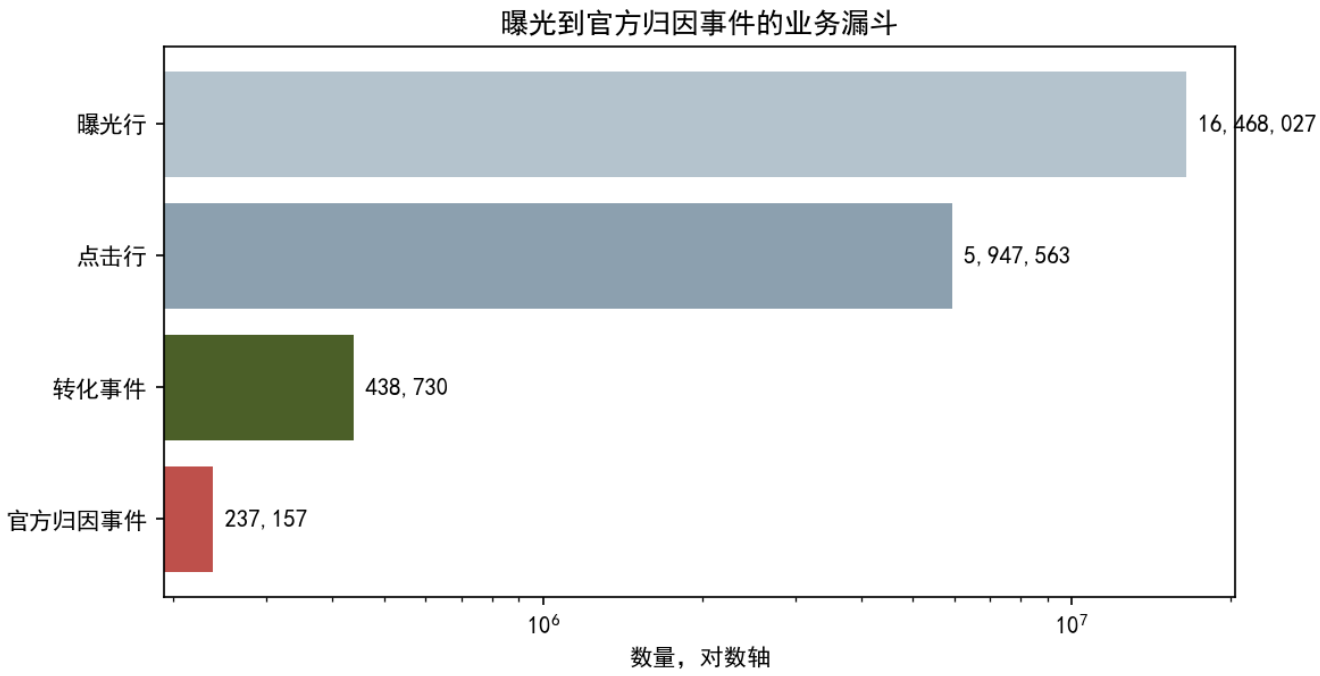
样本点击率为 36.12%，明显高于常见展示广告水平，因此项目没有引用绝对 CPA 作为行业结论。IPW 风格敏感性分析通过调整非点击曝光权重，将加权 CTR 强制到不同假设值，再观察绝对 CPA 和活动排名变化。

这里的 IPW 是压力测试，不是完整因果修正。转化分母没有做同等响应加权，因此不能把结果解释为无偏因果估计。

---

4. 分析结果

4.1 漏斗

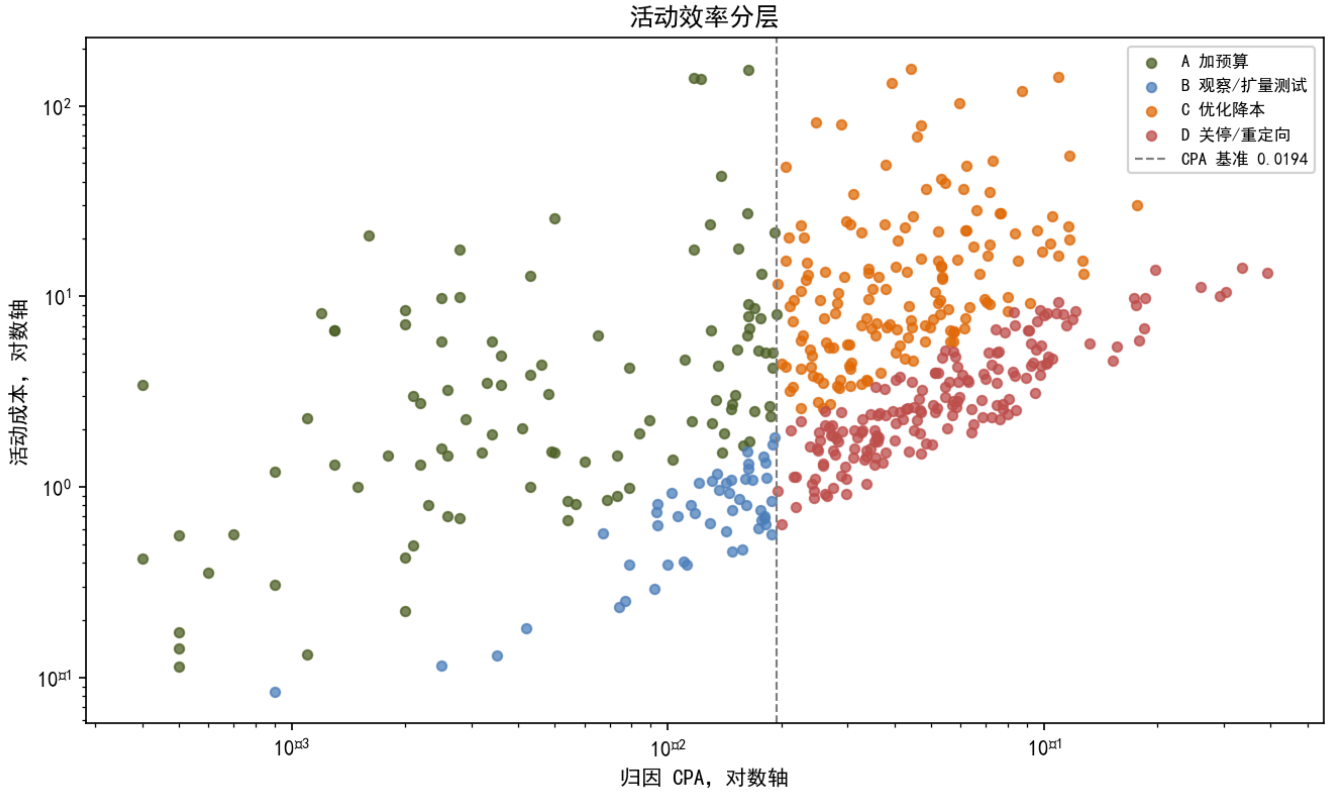


点击到转化是最大的业务流失环节：

- 5,141,367 个点击没有转化，占全部点击 86.44%。
- 点击转化率为 13.56%。
- 438,730 个转化事件中，237,157 个被官方归因，占 54.06%。

这说明继续增加曝光的优先级低于检查落地页承接、人群匹配和后续转化体验。但这是行级描述，不代表所有活动都具有相同问题，仍需按活动下钻。

4.2 活动效率

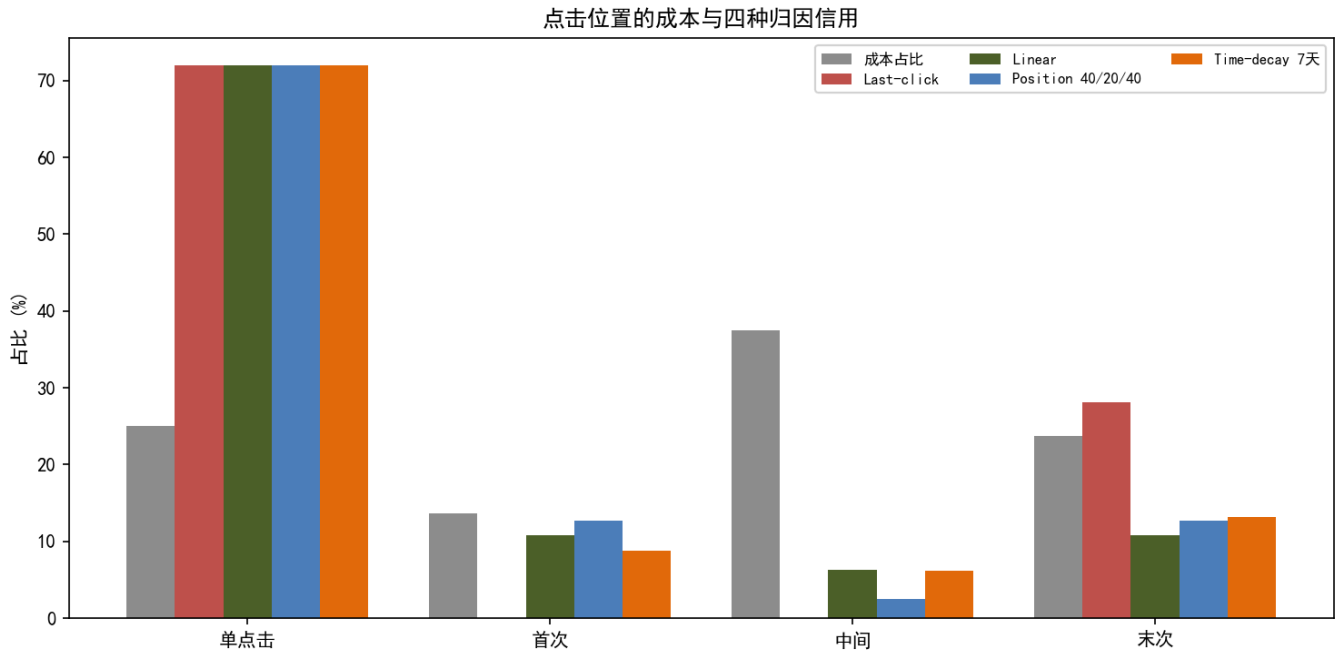


动作	活动数	归因事件	成本	全站成本占比	归因 CPA
A 加预算	104	154,663	954.3	19.8%	0.0062
B 观察或扩量测试	51	3,025	39.9	0.8%	0.0132
C 优化降本	155	66,395	2,917.5	60.4%	0.0439
D 关停或重定向	178	9,887	634.0	13.1%	0.0641

高效组包括 A 和 B，共 155 个活动，CPA 为 0.0063；低效组包括 C 和 D，共 333 个活动，CPA 为 0.0466。两组相差 7.4 倍。

C 和 D 合计占全站成本 73.5%，说明低效活动并非只存在于长尾。与此同时，7.4 倍是当前样本里的组间差异，不是预算迁移后可复制的提升倍数。

4.3 触点位置信用



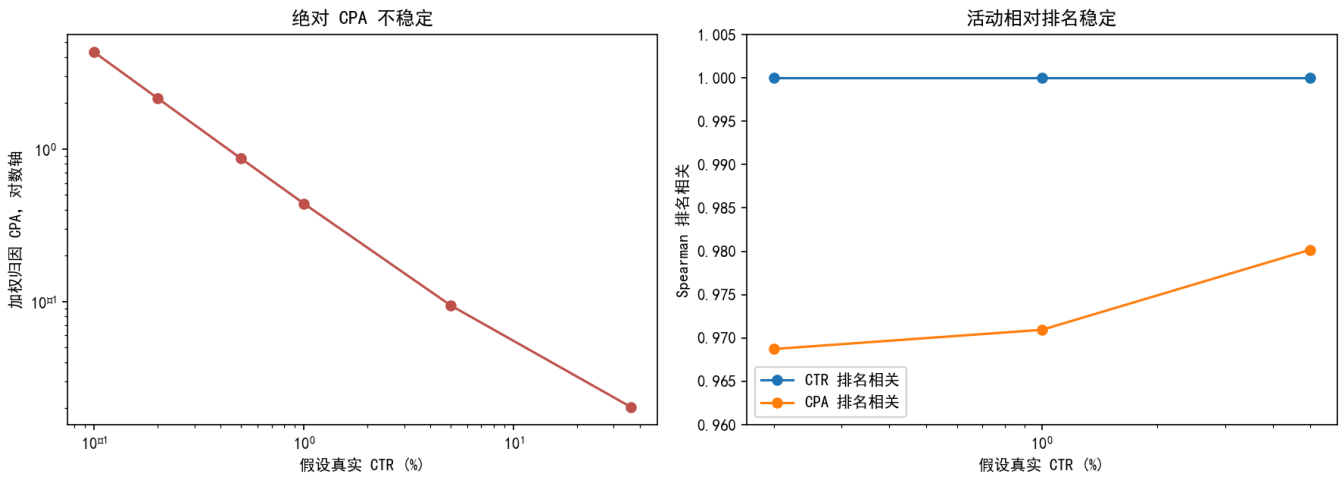
位置	路径行数	成本占比	Last-click	Linear	Position	Time-decay	三模型平均值	相对出价系数
单点击	260,774	25.07%	71.94%	71.94%	71.94%	71.94%	71.94%	2.870
首次	101,730	13.68%	0.00%	10.86%	12.75%	8.77%	10.79%	0.789
中间	135,911	37.50%	0.00%	6.35%	2.56%	6.13%	5.01%	0.134
末次	101,730	23.74%	28.06%	10.86%	12.75%	13.16%	12.26%	0.516

中间点击的成本占比约为三模型平均信用占比的 7.5 倍。即使采用三种不同的非末次归因规则，中间点击的信用仍然明显低于其成本占比。

单点击路径在所有模型中都获得 100% 的事件信用，因此其汇总信用占比达到 71.94%，相对系数为 2.870。这反映的是路径结构，不应解释为单次曝光具有三倍真实价值。

位置结论只覆盖完整路径。完整路径成本仅占全站成本 12.0%，不能直接外推到全部预算。

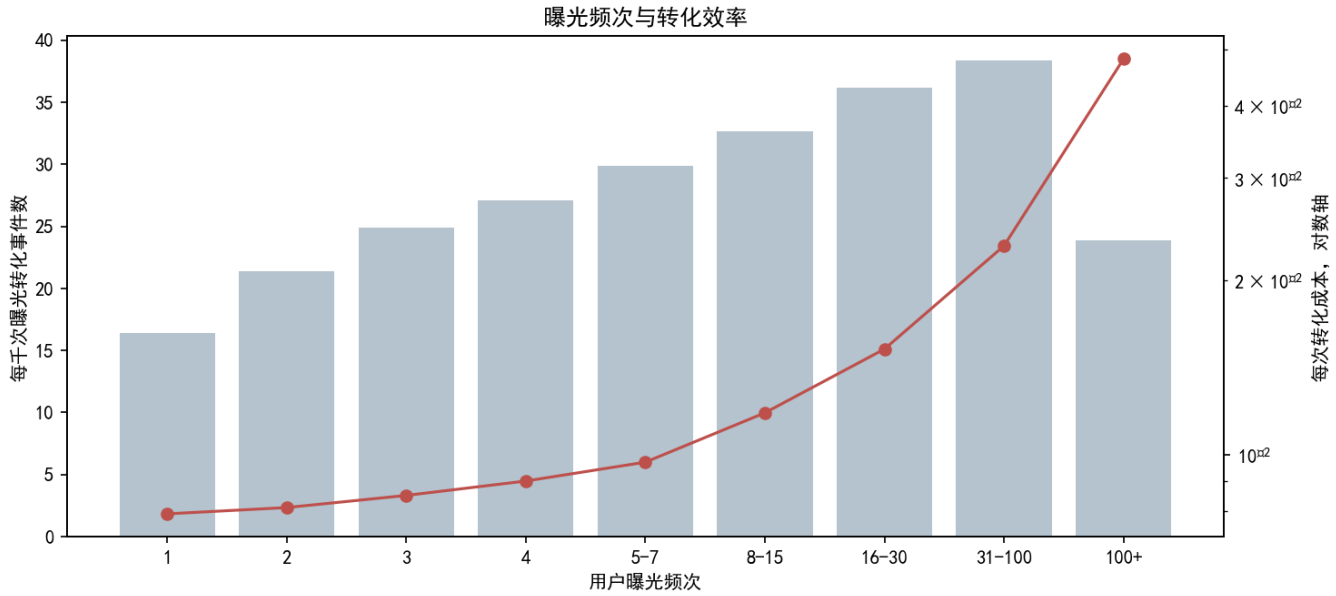
4.4 IPW 敏感性



假设 CTR	非点击权重	加权 CPA	成本倍数
0.10%	564.77	4.3085	211.58
0.20%	282.10	2.1585	106.00
0.50%	112.50	0.8685	42.65
1.00%	55.97	0.4385	21.53
5.00%	10.74	0.0945	4.64
36.12%	1.00	0.0204	1.00

绝对 CPA 最多浮动约 211 倍，因此不能与外部行业基准比较。活动 CTR 排名相关在所有情景下均为 1.0000，CPA 排名相关不低于 0.9687，说明相对预算排序比绝对成本水平更稳健。

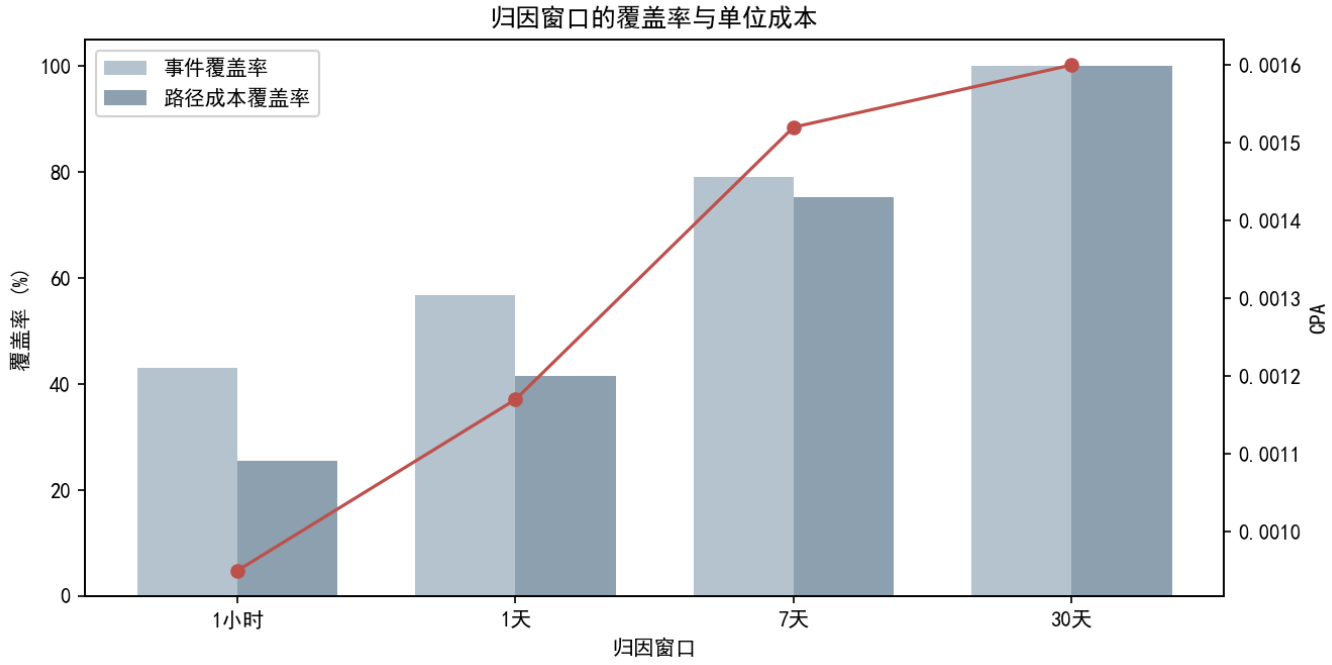
4.5 曝光频次



频次区间	用户占比	成本占比	每千曝光转化事件	单次转化成本
1	51.7%	8.5%	16.41	0.0079
2	19.4%	8.6%	21.39	0.0081
3	9.6%	7.8%	24.89	0.0085
4	5.6%	6.9%	27.10	0.0090
5 至 7	7.6%	16.2%	29.88	0.0097
8 至 15	4.7%	23.8%	32.68	0.0118
16 至 30	1.2%	16.7%	36.17	0.0152
31 至 100	0.2%	10.5%	38.40	0.0229
100 以上	0.0%	1.0%	23.86	0.0481

每千曝光转化事件在 16 至 30 次后基本走平，但单次转化成本继续上升。可以将 15 至 30 次视为性价比观察区间，不能解释为“多投 30 次必然多转化”。高频用户更可能本来就是高意向用户，存在内生性。

4.6 归因窗口



窗口	事件数	事件覆盖率	路径成本	成本覆盖率	窗口 CPA	边际 CPA
1 小时	156,006	43.0%	148.33	25.6%	0.00095	不适用
1 天	205,878	56.8%	241.21	41.6%	0.00117	0.00186
7 天	286,593	79.1%	436.36	75.2%	0.00152	0.00242
30 天	362,504	100.0%	580.27	100.0%	0.00160	0.00190

7 天窗口覆盖约八成完整路径事件和四分之三完整路径成本，适合日常成本观察。其 7 至 30 天的边际 CPA 为 0.00242，高于 30 天整体边际 CPA 0.00190，因此不能称为最低边际成本窗口。

官方 `attribution` 还表现出明显的小时级规则：末次点击在 1 分钟至 1 小时内的归因率约为 86.4%，1 小时至 1 天下降到 47.3%。该字段表示官方是否接受归因，不能当作触点信用。

---

5. 业务建议

5.1 活动预算

1. 从 A 类活动中优先选择规模足够、归因率正常、受众容量可验证的活动，先增加 20% 至 30% 预算。
2. C 类活动占成本 60.4%，先检查素材、人群、出价和落地页，再决定降本幅度。
3. D 类活动先做重定向或随机 holdout；连续低效后再考虑关停。
4. 不以 7.4 倍 CPA 差异作为提升承诺，只把它作为实验优先级的证据。

5.2 触点出价

1. 中间点击是当前最明显的成本信用错配点，但 0.134 不是可直接应用的最终出价系数。
2. 只在完整路径覆盖的预算范围内做小范围降低出价实验，建议先测试 10% 至 20% 的降价幅度。
3. 同时观察归因转化量、边际 CPA、频次和后续复购或质量指标，防止把高意向路径误伤。
4. 首次点击系数 0.789，接近中性；末次点击系数 0.516，不应继续获得与当前成本完全相称的预算。

5.3 频次与窗口

1. 减少第 30 次以上曝光的预算，把预算转向低频用户的前几次触达。
2. 使用频次上限实验验证拐点，不直接采用“15 至 30 次”作为固定业务阈值。
3. 成本观察使用 7 天窗口，完整效果评估使用 30 天窗口。

5.4 建议实验设计

项目	建议
实验单元	活动、广告组或可独立分配预算的受众包
处理组	A 类活动增加 20% 至 30% 预算；中间点击降低 10% 至 20% 出价
对照组	保持当前预算或出价，采用随机 holdout
周期	至少 2 至 4 周，覆盖完整转化窗口
主指标	增量转化事件或增量归因转化量
成本指标	边际 CPA、单位转化成本
护栏指标	转化质量、频次、流量容量、活动间预算挤压
停止条件	边际 CPA 持续恶化、转化质量下降或流量容量触顶

---

6. 局限

1. 数据是 Criteo 研究型构造样本，CTR 36.12% 和绝对 CPA 都不能代表真实广告行业水平。
2. 四种归因模型是规则型信用分配，不是因果提升估计。
3. 位置分析只覆盖 82.63% 的完整路径事件和 12.0% 的全站成本。
4. 频率与转化存在选择偏差和内生关系，高意向用户可能天然获得更多曝光。
5. 活动预算重分配忽略流量容量、边际收益递减、季节性和活动间竞争。
6. 数据没有收入和利润信息，CPA 只能作为代理指标，不能等同于 ROI。
7. 活动四类和动作阈值是描述性分析结果，不是经过统计显著性检验的因果分组。

---

7. 复现说明

7.1 环境

依赖版本记录在项目根目录的 `requirements.txt` 中。推荐使用 Python 3.13 或 3.14；当前依赖已在 Python 3.14.2 下验证，Notebook 原有执行元数据为 Python 3.13.9。建议在独立 Python 环境中安装：

```
python -m pip install -r requirements.txt
```

7.2 数据放置

原始数据需要放在：

```
data/raw/criteo_attribution_dataset.tsv
```

文件预期大小约为 2.59GB，SHA256 为：

```
0CD0C6EE363F9D6A47D9B6C6735159D22FFA4301F3B136B0C34BB00A68315BE3
```

7.3 运行顺序

从项目根目录依次运行：

```
01_business_analysis.ipynb
02_attribution_decision.ipynb
03_final_delivery.ipynb
```

三个 Notebook 共用持久化数据库：

```
data/criteo_analysis.duckdb
```

`01_business_analysis.ipynb` 会从原始 TSV 建立 `raw` 视图和业务汇总表。首次运行需要扫描 2.59GB 原始数据，后续查询直接使用 DuckDB 中的结果表。DuckDB 同一时间只允许一个写入连接，因此需要按顺序运行，并在继续下一个 Notebook 前等待当前连接关闭。

7.4 主要产物

路径	内容
`reports/figures/`	8 张业务图表
`reports/tableau/`	18 张 Tableau 数据表
`data/criteo_analysis.duckdb`	可复用的 DuckDB 分析数据库

当前版本提供 Tableau 数据导出，但尚未包含可交互的 `.twb/.twbx` 看板。